

Product Requirements Document — RAG Chatbot

- LLM & Agentics Kurs (Prof. Saile)
- Executive Summary
- Case Definition
- Required Document Database (5 PDFs)
- Example Questions (Demo)
- Important Risks (HR-spezifisch)
- Requirements
- Tech Stack
- Architecture
- Documentation Structure (10 Pages)
- Presentation Structure (15 Min)
- EU AI Act Analysis (für Doku)
- Roadmap
- Success Criteria für 1.0
- Risks & Mitigations
- Notes

Product Requirements Document

— RAG Chatbot

LLM & Agentics Kurs (Prof. Saile)

Status: Active

Submission Deadline: 31.05.2026

Presentation: 01.06.2026 (15 Min + 10 Min Q&A)

Team: Gruppe 1 (Juliana Paar, Anastasiia Sereda, Rustam Kohen)

Goal: Note 1.0 🎯

Executive Summary

Case 1 — HR Knowledge Assistant für BergTech Maschinenbau GmbH

Entwicklung eines RAG-Chatbots, der HR-Mitarbeiter und Angestellte bei repetitiven Fragen entlastet (Onboarding, Urlaubsregeln, Trainings, interne HR-Prozesse). Stack: **n8n (lokal)** + **Supabase** + **OpenRouter/OpenAI**.

Case Definition

Company Situation

BergTech Maschinenbau GmbH — mittelständisches Maschinenbauunternehmen, 450 Mitarbeiter. Die HR-Abteilung erhält viele repetitive Fragen zu Onboarding, Urlaub, Trainings und internen Prozessen.

Main Focus

- Employee Knowledge Access
- Onboarding Efficiency
- HR Compliance

Target Users

- Neue Mitarbeiter (Onboarding-Fragen)
 - Bestehende Mitarbeiter (Urlaub, Trainings, Policies)
 - HR-Team (Entlastung von Routine-Anfragen)
-

Required Document Database (5 PDFs)

#	Dokument	Inhalt
1	Onboarding Guide	First-Day Checklist, benötigte Dokumente, Ansprechpartner
2	Vacation and Absence Policy	Urlaubsregeln, Antragsfristen, Krankmeldung
3	Training and Compliance Policy	Pflichttrainings, Compliance, Schulungspläne
4	HR FAQ Document	Top 20 wiederkehrende Fragen
5	Employee Offboarding Checklist	Austrittsprozess, Übergabe, Equipment

Example Questions (Demo)

1. **Was muss ein neuer Mitarbeiter vor seinem ersten Arbeitstag einreichen?**
 2. **Wie viele Tage im Voraus muss Urlaub beantragt werden?**
 3. **Welche Pflichttrainings müssen neue Mitarbeiter im Onboarding absolvieren?**
-

Important Risks (HR-spezifisch)

- **Falsche HR-Guidance** → kann rechtliche Konsequenzen haben
 - **Halluzinierte Policy-Infos** → Vertrauen verloren, Fehlentscheidungen
 - **Verarbeitung sensibler Mitarbeiterdaten** → DSGVO-Risiko
-

Requirements

Functional Requirements

Req	Beschreibung	Priority
FR1	Chatbot beantwortet 3 Demo-Fragen korrekt	MUST
FR2	Live-Demo während Präsentation funktioniert	MUST
FR3	n8n Workflow als JSON exportierbar	MUST
FR4	PDFs → Vektoren → Vector Store Pipeline	MUST
FR5	Ähnlichkeitssuche retrievet relevante Docs	MUST
FR6	LLM generiert auf Basis gefundener Docs	MUST
FR7	Quellen werden im Chat angezeigt	SHOULD
FR8	“Ich weiß nicht“-Fallback bei unbekannten Fragen	SHOULD

Non-Functional Requirements

Req	Beschreibung	Priority
NFR1	n8n: 3-4 Hauptnodes (Saile's Tip)	MUST
NFR2	Latenz < 10s pro Query	SHOULD
NFR3	Reproduzierbar dokumentiert	MUST
NFR4	Hosting: lokal (n8n self-hosted)	MUST
NFR5	Bonus: Online deploybar (für 1.0!)	NICE TO HAVE

Deliverables

Deliverable	Format	Submission	Due
Project Documentation	PDF	Teams (1x pro Gruppe)	31.05
Presentation Slides	PDF/PPTX	Teams (1x pro Gruppe)	31.05
n8n Workflows	JSON Export	Teams (1x pro Gruppe)	31.05
Individual Grading Report	PDF/Word	Teams (jeder einzeln)	31.05
Live Presentation	—	In-Person	01.06

Tech Stack

Primary

- **n8n (lokal/self-hosted)** — Workflow Orchestration
- **Supabase** — Vector Database (pgvector)
- **OpenRouter / OpenAI** — LLM + Embeddings


Hosting Strategy

- **Default:** Lokal (n8n self-hosted via Docker)
- **Bonus für 1.0:** Online deployment (z.B. Railway, Render, oder n8n cloud trial)

Why these choices

- **n8n** — visuelle Workflows, einfacher Export als JSON
- **Supabase** — pgvector kostenlos, einfach zu set-upen
- **OpenRouter** — flexible Model-Wahl, günstig

Architecture



Node Details

Workflow 1 — Ingestion (3 Nodes): 1. Manual/File Trigger 2. Read PDF Files 3. Supabase Vector Store (Insert) ← Sub-Nodes: Embedding + Splitter

Workflow 2 — Query (3 Nodes): 1. Chat Trigger (Webhook) 2. AI Agent ← Sub-Nodes: LLM + Vector Tool + Memory 3. Response (im Chat Trigger oder separat)

Documentation Structure (10 Pages)

#	Section	Pages	Inhalt
1	Cover + Inhaltsverzeichnis	1	Titel, Team, Datum
2	Company Situation	1	BergTech HR Case, Problem, Zielgruppe
3	Architecture Overview	1	Diagramm, Stack-Begründung
4	Workflow Details	2	Ingestion + Query Workflow Node-by-Node
5	Example Questions + Demo	1	3 Fragen mit Chatbot-Antworten (Screenshots)
6	Risk Assessment	1.5	2 Ebenen: (1) Praxis-Risiken bei Nutzung (Halluzination, DSGVO, Outdated Info) + Mitigationen; (2) EU AI Act Compliance-Risiken (Art. 50, Art. 4 Verstöße) + Maßnahmen
7	EU AI Act Analysis	1.5	Rollen explizit (Provider = wir, Deployer = BergTech, Affected Persons = Mitarbeiter, GPAI = OpenAI); Risikoklasse Limited-Risk; Pflichten + Umsetzung
8	Implementation Reflection	1	Struktur: Was gut geklappt hat / Was schlecht lief / Konkrete Probleme + Lösungsweg / Learnings
Total		10	

Appendix (unbegrenzt): n8n Screenshots, JSON Export, Logs, Extended Configs

Presentation Structure (15 Min)

Min	Content
0-2	Problem + Use Case (BergTech HR)
2-3	RAG-Konzept + Why RAG (1 Min reicht)
3-6	Architektur + n8n Workflows (Screens)
6-10	Live Chatbot Demo (3 Fragen)
10-13	Risks, Safeguards, EU AI Act (inkl. Rollen)
13-15	Reflection: Was gut/schlecht lief, Probleme + Lösungen, Learnings

Q&A: 10 Min (vorbereitete Antworten zu wahrscheinlichsten Fragen)

EU AI Act Analysis (für Doku)

Rollenklassifikation

- **Provider:** Du (entwickelst Chatbot)
- **Deployer:** BergTech (setzt ihn ein)
- **Affected Persons:** Mitarbeiter
- **GPAI Provider:** OpenAI/Anthropic (wir nutzen API)

Risikoklasse

Limited-Risk (Chatbots mit menschlicher Interaktion)

Pflichten

- **Art. 50 Transparenz:** User-Hinweis "Du chattest mit KI"
- **Art. 4 AI Literacy:** Mitarbeiter-Schulung über Funktionsweise + Grenzen
- **Quellenangabe:** Antworten zeigen verwendete Dokumente

Risks + Safeguards Tabelle

Risk	Mitigation
Halluzinationen	Quellen-Display, "Ich weiß nicht"-Fallback
Bias	Test-Suite mit diversen Fragen
DSGVO/Datenschutz	Lokale Verarbeitung, keine PII in Vectors
Outdated Info	Regelmäßige Re-Indexierung
Prompt Injection	Input Sanitization

Roadmap

✓ Phase 1: Planning (heute, 09.05)



PRD erstellt



Ordnerstruktur



Case definiert (Case 1 — BergTech HR)



Testfragen identifiziert



PDF-Konzepte (5 Stück)

Phase 2: Document Creation (10.-12.05)



Onboarding Guide schreiben



Vacation Policy



Training Policy



HR FAQ



Offboarding Checklist



PDFs in `/company-docs/`

Phase 3: Setup (13.-15.05)

☐

Supabase Project (pgvector)

☐

OpenRouter API Key

☐

n8n lokal via Docker

☐

Erste Workflow-Skeletons

Phase 4: Implementation (16.-22.05)

☐

Workflow 1: Ingestion

☐

PDFs erfolgreich indexiert

☐

Workflow 2: Query/Chat

☐

E2E Test mit 3 Fragen

☐

JSON Exports

☐

Bonus: Online Deployment

Phase 5: Documentation (23.-27.05)

☐

10-Seiten Doku

☐

EU AI Act Section

☐

Screenshots + Diagramme

☐

Reflection Section

☐

PDF Generation

Phase 6: Presentation Prep (28.-31.05)

☐

Slides (15 Min)

☐

Speaker Notes

☐

Live Demo Rehearsal (3-5x!)

☐

Q&A Vorbereitung

☐

Contribution Reports

☐

Submission 31.05

Phase 7: Live Day (01.06)

☐

Setup Check (1h vorher)

☐

Live Demo durchführen

☐

Q&A meistern

☐

🎓 1.0!

Success Criteria für 1.0

✅ **Hard Requirements:** - [] Chatbot beantwortet alle 3 Testfragen korrekt - [] Live Demo läuft fehlerfrei - [] n8n Workflows als JSON exportiert - [] 10-Seiten Doku ohne Lücken - [] EU AI Act Analyse vollständig - [] Präsentation 15 Min ± 1 Min - [] Q&A souverän

✅ **For 1.0 (Bonus):** - [] **Online Deployment** (extra credit) - [] Source Attribution im Chatbot UI - [] Tiefgreifende EU AI Act Analyse (über Mindestmaß) - [] Polished Slides (visuell stark) - [] Alle Q&A Fragen bombenfest - [] Demonstration von Edge-Cases (z.B. unbekannte Frage → Fallback) - [] Reflection mit ehrlichen Learnings

Risks & Mitigations

Risk	Impact	Mitigation
Live Demo bricht ab	HIGH	5× rehearse, Fallback Screenshots/Video
n8n local instabil	MEDIUM	Docker Setup robust, Backup Workflow
LLM halluziniert	MEDIUM	System Prompt streng, Few-Shots
PDF Extract fehlerhaft	MEDIUM	Test mit verschiedenen PDFs
Timing zu lang	MEDIUM	Dry-Run mit Stoppuhr
EU AI Act ungültig	HIGH	Mit Saile gegenchecken
Q&A schwierige Fragen	MEDIUM	Top 10 Fragen vorbereiten

Notes

- **Saile's Tips:**
 - n8n klein halten (3-4 Nodes)
 - Live Demo ist kritisch
 - EU AI Act ist Pflicht
 - Präsentation > Doku im Grading
 - Lokal reicht, online ist Bonus
- **Goal: 1.0** — Online Deployment als Differenziator
- **Submission:** Doku + Präsentation = 1x pro Gruppe; Individual Grading Report = jeder einzeln
- **Confidential:** Contribution Report nicht mit Team besprechen

Last Updated: 09.05.2026

Next Review: Nach Phase 2 (PDFs fertig)

Status: 🟡 Phase 1 → Phase 2 transition