

Product Requirements Document — RAG Chatbot

- LLM & Agentics Kurs (Prof. Saile) | v4
- Executive Summary
- Case Definition
- Required Document Database (5 PDFs)
- Example Questions (Demo)
- Important Risks (HR-spezifisch)
- Requirements
- Tech Stack
- Architecture
- Documentation Structure (10 Pages)
- Presentation Structure (15 Min)
- EU AI Act Analysis (für Doku)
- Aufgabenverteilung
- Roadmap
- Success Criteria für 1.0
- Risks & Mitigations
- Notes

Product Requirements Document

— RAG Chatbot

LLM & Agentics Kurs (Prof. Saile) | v4

Status: Active

Version: 4.0 (09.05.2026)

Submission Deadline: 31.05.2026

Presentation: 01.06.2026 (15 Min + 10 Min Q&A)

Team: Gruppe 1 (Juliana Paar, Anastasiia Sereda, Rustam Kohen)

Goal: Note 1.0

Executive Summary

Case 1 — HR Knowledge Assistant für BergTech Maschinenbau GmbH

Entwicklung eines RAG-Chatbots, der HR-Mitarbeiter und Angestellte bei repetitiven Fragen entlastet (Onboarding, Urlaubsregeln, Trainings, interne HR-Prozesse). Stack: **n8n (lokal)** + **Supabase** + **OpenRouter/OpenAI**.

Case Definition

Company Situation

BergTech Maschinenbau GmbH — mittelständisches Maschinenbauunternehmen, 450 Mitarbeiter. Die HR-Abteilung erhält viele repetitive Fragen zu Onboarding, Urlaub, Trainings und internen Prozessen.

Main Focus

- Employee Knowledge Access
- Onboarding Efficiency
- HR Compliance

Target Users

- Neue Mitarbeiter (Onboarding-Fragen)
- Bestehende Mitarbeiter (Urlaub, Trainings, Policies)
- HR-Team (Entlastung von Routine-Anfragen)

Required Document Database (5 PDFs)

#	Dokument	Inhalt
1	Onboarding Guide	First-Day Checklist, benötigte Dokumente, Ansprechpartner
2	Vacation and Absence Policy	Urlaubsregeln, Antragsfristen, Krankmeldung
3	Training and Compliance Policy	Pflichttrainings, Compliance, Schulungspläne
4	HR FAQ Document	Top 20 wiederkehrende Fragen
5	Employee Offboarding Checklist	Austrittsprozess, Übergabe, Equipment

Document Authoring Guidelines (RAG-Optimized)

Die 5 Dokumente werden so strukturiert, dass Chunking + Retrieval optimal funktionieren.

TO DO: - Klare Überschriften und Unterüberschriften (H1/H2/H3 sauber genutzt) - Inhalte in kurze, thematisch abgeschlossene Abschnitte - Konsistente Fachbegriffe, alle relevanten Begriffe explizit nennen - Präzise und eindeutige Formulierungen, nur eine Schriftart - Listen und nummerierte Schritte bei Prozessen - Semantischer Zusammenhang innerhalb einzelner Abschnitte - Sinnvolle Metadaten und Kontextinformationen ergänzen - Informationsdicht und sachlich schreiben

NOT TO DO: - Keine extrem langen Fließtexte - Keine unnötigen Wiederholungen oder Marketing-Sprache - Keine Themenmischung innerhalb eines Abschnitts - Keine unklaren Abkürzungen ohne Erklärung - Keine rein visuellen Informationen ohne Textbeschreibung - Keine Tabellen oder Grafiken ohne Kontext - Keine widersprüchlichen oder veralteten Informationen - Keine riesigen Dokumentblöcke ohne Struktur

Begründung: RAG-Systeme zerteilen Dokumente in Chunks (z.B. 500-800 Token). Je sauberer ein Chunk ein abgeschlossenes Thema enthält, desto präziser das Retrieval und desto weniger Halluzinationen. Wirkt direkt auf die Demo-Antwortqualität.

Example Questions (Demo)

1. Was muss ein neuer Mitarbeiter vor seinem ersten Arbeitstag einreichen?
 2. Wie viele Tage im Voraus muss Urlaub beantragt werden?
 3. Welche Pflichttrainings müssen neue Mitarbeiter im Onboarding absolvieren?
-

Important Risks (HR-spezifisch)

- **Falsche HR-Guidance** → kann rechtliche Konsequenzen haben
 - **Halluzinierte Policy-Infos** → Vertrauen verloren, Fehlentscheidungen
 - **Verarbeitung sensibler Mitarbeiterdaten** → DSGVO-Risiko
-

Requirements

Functional Requirements

Req	Beschreibung	Priority
FR1	Chatbot beantwortet 3 Demo-Fragen korrekt	MUST
FR2	Live-Demo während Präsentation funktioniert	MUST
FR3	n8n Workflow als JSON exportierbar	MUST
FR4	PDFs → Vektoren → Vector Store Pipeline	MUST
FR5	Ähnlichkeitssuche retrievet relevante Docs	MUST
FR6	LLM generiert auf Basis gefundener Docs	MUST
FR7	Quellen werden im Chat angezeigt	SHOULD
FR8	“Ich weiß nicht“-Fallback bei unbekannten Fragen	SHOULD

Non-Functional Requirements

Req	Beschreibung	Priority
NFR1	n8n: 3-4 Hauptnodes (Saile's Tip)	MUST
NFR2	Latenz < 10s pro Query	SHOULD
NFR3	Reproduzierbar dokumentiert	MUST
NFR4	Hosting: lokal (n8n self-hosted)	MUST
NFR5	Bonus: Online deploybar (für 1.0!)	NICE TO HAVE

Deliverables

Deliverable	Format	Submission	Due
Project Documentation	PDF	Teams (1x pro Gruppe)	31.05
Presentation Slides	PDF/PPTX	Teams (1x pro Gruppe)	31.05
n8n Workflows	JSON Export	Teams (1x pro Gruppe)	31.05
Individual Grading Report	PDF/Word	Teams (jeder einzeln)	31.05
Live Presentation	—	In-Person	01.06

Tech Stack

Primary

- **n8n (lokal/self-hosted)** — Workflow Orchestration
- **Supabase** — Vector Database (pgvector)
- **OpenRouter / OpenAI** — LLM + Embeddings


Hosting Strategy

- **Default:** Lokal (n8n self-hosted via Docker)
- **Bonus für 1.0:** Online deployment (z.B. Railway, Render, oder n8n cloud trial)

Why these choices

- **n8n** — visuelle Workflows, einfacher Export als JSON
- **Supabase** — pgvector kostenlos, einfach zu set-upen
- **OpenRouter** — flexible Model-Wahl, günstig

Architecture



Node Details

Workflow 1 — Ingestion (3 Nodes): 1. Manual/File Trigger 2. Read PDF Files 3. Supabase Vector Store (Insert) ← Sub-Nodes: Embedding + Splitter

Workflow 2 — Query (3 Nodes): 1. Chat Trigger (Webhook) 2. AI Agent ← Sub-Nodes: LLM + Vector Tool + Memory 3. Response (im Chat Trigger oder separat)

Documentation Structure (10 Pages)

#	Section	Pages	Inhalt
1	Cover + Inhaltsverzeichnis	1	Titel, Team, Datum
2	Company Situation	1	BergTech HR Case, Problem, Zielgruppe
3	Architecture Overview	1	Diagramm, Stack-Begründung
4	Workflow Details	2	Ingestion + Query Workflow Node-by-Node
5	Example Questions + Demo	1	3 Fragen mit Chatbot-Antworten (Screenshots)
6	Risk Assessment	1.5	2 Ebenen: (1) Praxis-Risiken bei Nutzung (Halluzination, DSGVO, Outdated Info) + Mitigationen; (2) EU AI Act Compliance-Risiken (Art. 50, Art. 4 Verstöße) + Maßnahmen
7	EU AI Act Analysis	1.5	Rollen explizit (Provider = wir, Deployer = BergTech, Affected Persons = Mitarbeiter, GPAI = OpenAI); Risikoklasse Limited-Risk; Pflichten + Umsetzung
8	Implementation Reflection	1	Struktur: Was gut geklappt hat / Was schlecht lief / Konkrete Probleme + Lösungsweg / Learnings
Total		10	

Appendix (unbegrenzt): n8n Screenshots, JSON Export, Logs, Extended Configs

Presentation Structure (15 Min)

Min	Content
0-2	Problem + Use Case (BergTech HR)
2-3	RAG-Konzept + Why RAG (1 Min reicht)
3-6	Architektur + n8n Workflows (Screens)
6-10	Live Chatbot Demo (3 Fragen)
10-13	Risks, Safeguards, EU AI Act (inkl. Rollen)
13-15	Reflection: Was gut/schlecht lief, Probleme + Lösungen, Learnings

Q&A: 10 Min (vorbereitete Antworten zu wahrscheinlichsten Fragen)

Backup Slides (ausgeblendet, nach Slide 1): - Node-by-Node Erklärung Ingestion Workflow (Detail) - Node-by-Node Erklärung Query Workflow (Detail) - EU AI Act Artikel-Texte (Art. 50, Art. 4) im Wortlaut - Embedding-Konzept visuell erklärt - Supabase pgvector Setup-Details - Edge Cases: Was passiert bei unbekannter Frage (Fallback) - Kostenübersicht OpenRouter (Token-Kosten)

EU AI Act Analysis (für Doku)

Rollenklassifikation

- **Provider:** Du (entwickelst Chatbot)
- **Deployer:** BergTech (setzt ihn ein)
- **Affected Persons:** Mitarbeiter
- **GPAI Provider:** OpenAI/Anthropic (wir nutzen API)

Risikoklasse

Limited-Risk (Chatbots mit menschlicher Interaktion)

Pflichten

- **Art. 50 Transparenz:** User-Hinweis "Du chattest mit KI"
- **Art. 4 AI Literacy:** Mitarbeiter-Schulung über Funktionsweise + Grenzen
- **Quellenangabe:** Antworten zeigen verwendete Dokumente

Risks + Safeguards Tabelle

Risk	Mitigation
Halluzinationen	Quellen-Display, "Ich weiß nicht"-Fallback
Bias	Test-Suite mit diversen Fragen
DSGVO/Datenschutz	Lokale Verarbeitung, keine PII in Vectors
Outdated Info	Regelmäßige Re-Indexierung
Prompt Injection	Input Sanitization

Aufgabenverteilung

Person	Rolle	Verantwortung
Anastasiia Sereda	EU AI Act Lead (vorerst)	EU AI Act Analyse: Rollen-Klassifikation (Provider/Deployer/Affected Persons/GPAI), Risikoklasse Limited-Risk, Pflichten Art. 50 + Art. 4, Compliance-Risiken + Mitigationen
Juliana Paar	Supabase Lead (Vorschlag)	Supabase Setup (pgvector), Schema, Embedding Storage, Retrieval-Konfiguration, Anbindung an n8n
Rustam Kohen	n8n Lead	n8n Workflows (Ingestion + Query), OpenRouter Integration, Live-Demo, JSON Export, optional Online-Deployment

HR-Dokumente — Best-of-Approach

Alle drei Teammitglieder erstellen **eigenständig je 5 HR-Dokumente** nach den RAG-Authoring-Guidelines. Im Team-Vergleich wird pro Dokument-Typ das beste Ergebnis ausgewählt.

Vorteil: Bessere Endqualität, mehr Variationen für Vergleich, jeder lernt RAG-Optimierung praktisch.

Workflow: 1. Jeder erstellt die 5 Dokumente (Onboarding, Vacation, Training, FAQ, Offboarding) in eigenem Ordner - `company-docs/rustam/` - `company-docs/juliana/` - `company-docs/anastasiia/` 2. Team-Review: pro Dokument-Typ das beste auswählen 3. Auswahl wird in `company-docs/final/` gemerged → finale 5 PDFs für Ingestion

Offen für spätere Verteilung: 10-Seiten-Doku (Sections schreiben), Präsentation + Backup-Slides, finale MD→PDF-Konvertierung, Individual Grading Reports (jeder selbst).

Cross-Functional

- **Live-Demo Rehearsal:** alle 3 zusammen (mind. 3× vor 01.06)
- **Q&A-Vorbereitung:** alle 3 (jeder kennt Top 10 Fragen)
- **Individual Grading Report:** jeder schreibt seinen eigenen
- **Review-Loops:** Doku → Cross-Read durch alle, Slides → Cross-Read durch alle

Iteration Tracking

Rustam dokumentiert jede n8n-Build-Iteration in `BUILD_LOG.md` : - Was gebaut, welche Konfiguration, welche Probleme + Lösung - Screenshots in `/workflows/screens/` - Take-Aways für Doku (Juliana) und Slides (Anastasiia)

→ Juliana und Anastasiia ziehen aus dem BUILD_LOG die nötigen Inhalte für ihre Deliverables.

Roadmap

✅ Phase 1: Planning (heute, 09.05)



PRD erstellt



Ordnerstruktur



Case definiert (Case 1 — BergTech HR)



Testfragen identifiziert



PDF-Konzepte (5 Stück)

Phase 2: Document Creation (10.-12.05)



Onboarding Guide schreiben



Vacation Policy



Training Policy



HR FAQ



Offboarding Checklist

☐

PDFs in `/company-docs/`

Phase 3: Setup (13.-15.05)

☐

Supabase Project (pgvector)

☐

OpenRouter API Key

☐

n8n lokal via Docker

☐

Erste Workflow-Skeletons

Phase 4: Implementation (16.-22.05)

☐

Workflow 1: Ingestion

☐

PDFs erfolgreich indexiert

☐

Workflow 2: Query/Chat

☐

E2E Test mit 3 Fragen

☐

JSON Exports

☐

Bonus: Online Deployment

Phase 5: Documentation (23.-27.05)

☐

10-Seiten Doku

☐

EU AI Act Section

☐

Screenshots + Diagramme

☐

Reflection Section

☐

PDF Generation

Phase 6: Presentation Prep (28.-31.05)

☐

Slides (15 Min)

☐

Speaker Notes

☐

Live Demo Rehearsal (3-5x!)

☐

Q&A Vorbereitung

☐

Contribution Reports

☐

Submission 31.05

Phase 7: Live Day (01.06)

☐

Setup Check (1h vorher)

☐

Live Demo durchführen

☐

Q&A meistern

☐

🎓 1.0!

Success Criteria für 1.0

✅ **Hard Requirements:** - [] Chatbot beantwortet alle 3 Testfragen korrekt - [] Live Demo läuft fehlerfrei - [] n8n Workflows als JSON exportiert - [] 10-Seiten Doku ohne Lücken - [] EU AI Act Analyse vollständig - [] Präsentation 15 Min ± 1 Min - [] Q&A souverän

✅ **For 1.0 (Bonus):** - [] **Online Deployment** (extra credit) - [] Source Attribution im Chatbot UI - [] Tiefgreifende EU AI Act Analyse (über Mindestmaß) - [] Polished Slides (visuell stark) - [] Alle Q&A Fragen bombenfest - [] Demonstration von Edge-Cases (z.B. unbekannte Frage → Fallback) - [] Reflection mit ehrlichen Learnings

Risks & Mitigations

Risk	Impact	Mitigation
Live Demo bricht ab	HIGH	5× rehearse, Fallback Screenshots/Video
n8n local instabil	MEDIUM	Docker Setup robust, Backup Workflow
LLM halluziniert	MEDIUM	System Prompt streng, Few-Shots
PDF Extract fehlerhaft	MEDIUM	Test mit verschiedenen PDFs
Timing zu lang	MEDIUM	Dry-Run mit Stoppuhr
EU AI Act ungültig	HIGH	Mit Saile gegenchecken
Q&A schwierige Fragen	MEDIUM	Top 10 Fragen vorbereiten

Notes

- **Saile's Tips:**
 - n8n klein halten (3-4 Nodes)
 - Live Demo ist kritisch
 - EU AI Act ist Pflicht
 - Präsentation > Doku im Grading
 - Lokal reicht, online ist Bonus
- **Goal: 1.0** — Online Deployment als Differenziator
- **Submission:** Doku + Präsentation = 1x pro Gruppe; Individual Grading Report = jeder einzeln
- **Confidential:** Contribution Report nicht mit Team besprechen

Last Updated: 09.05.2026

Next Review: Nach Phase 2 (PDFs fertig)

Status: 🟡 Phase 1 → Phase 2 transition